

Document de test OCR

Corpus de tableaux pour pipeline RAG actuariel

Ce document a été généré automatiquement pour tester l'extraction de texte et de tableaux par un moteur OCR (Tesseract, docling, Azure Document Intelligence, etc.). Il contient dix pages mêlant paragraphes courants, tableaux financiers, techniques et démographiques.

L'objectif est de vérifier la qualité de l'extraction sur des structures hétérogènes : tableaux à colonnes étroites, valeurs numériques avec séparateurs, en-têtes fusionnés conceptuellement, et alternance texte/tableau dans la même page.

Métadonnées du document

Champ	Valeur
Titre	Document de test OCR — Tableaux
Version	1.0
Date	22 mai 2026
Pages	10
Langue	Français
Encodage	UTF-8
Format	PDF/A compatible

1. Bilan comptable au 31/12/2025

Présentation simplifiée du bilan d'une compagnie d'assurance fictive. Les montants sont exprimés en milliers d'euros.

Poste	2024 (k€)	2025 (k€)	Variation
Immobilisations incorporelles	12 450	13 820	+11,0 %
Immobilisations corporelles	84 300	86 100	+2,1 %
Placements financiers	1 245 600	1 312 400	+5,4 %
Créances	76 200	82 050	+7,7 %
Disponibilités	42 800	38 900	-9,1 %
Total actif	1 461 350	1 533 270	+4,9 %
Capitaux propres	412 000	438 500	+6,4 %
Provisions techniques	956 700	998 200	+4,3 %
Dettes	92 650	96 570	+4,2 %
Total passif	1 461 350	1 533 270	+4,9 %

Le total bilanciel progresse de 4,9 % sur l'exercice, porté principalement par la valorisation du portefeuille de placements.

2. Grille tarifaire automobile 2026

Prime annuelle de référence (formule tous risques, véhicule de catégorie B, conducteur sans malus, zone géographique 3).

Tranche d'âge	Prime H (€)	Prime F (€)	Coef. malus max	Réduction max
18 – 21 ans	1 890	1 720	3,50	0 %
22 – 25 ans	1 420	1 290	2,80	10 %
26 – 30 ans	980	920	2,50	20 %
31 – 40 ans	740	710	2,50	35 %
41 – 50 ans	680	650	2,50	50 %
51 – 60 ans	650	620	2,50	50 %
61 – 70 ans	720	690	2,50	50 %
71 – 80 ans	890	850	2,50	40 %
81 ans et +	1 150	1 100	2,50	30 %

Les écarts homme/femme sont conservés à titre historique mais ne sont plus appliqués en tarification effective depuis 2012 (arrêt Test-Achats de la CJUE, 1er mars 2011).

3. Méthodologie de provisionnement

Le provisionnement technique en assurance non-vie repose sur l'estimation des engagements futurs de l'assureur envers ses assurés. Cette estimation s'appuie sur des méthodes actuarielles éprouvées, dont les plus répandues sont la méthode Chain-Ladder, la méthode Bornhuetter-Ferguson et les approches GLM (modèles linéaires généralisés).

La méthode Chain-Ladder, introduite dans les années 1970, exploite la régularité du développement des sinistres pour projeter les paiements futurs à partir d'un triangle de liquidation. Sa simplicité de mise en œuvre en a fait un standard de la profession, malgré ses limites lorsque le portefeuille présente des sinistres atypiques ou des changements de processus de gestion.

L'approche Bornhuetter-Ferguson combine l'estimation Chain-Ladder avec une charge ultime a priori, généralement issue de l'expérience tarifaire. Elle est particulièrement utile pour les exercices récents, où la part de sinistres déjà déclarés reste faible et où la projection pure Chain-Ladder serait instable.

Les modèles GLM, plus sophistiqués, permettent de modéliser explicitement la distribution des coûts de sinistres et d'intégrer des variables explicatives (zone, type de garantie, ancienneté du contrat). Ils sont aujourd'hui le socle des approches Solvabilité II pour le calcul du SCR non-vie.

Le choix de la méthode dépend de plusieurs facteurs : profondeur de l'historique disponible, homogénéité du portefeuille, stabilité des processus de gestion, et exigences réglementaires applicables. Une bonne pratique consiste à croiser plusieurs méthodes pour borner l'incertitude sur l'estimation finale.

4. Triangle de liquidation (paiements cumulés)

Triangle de liquidation des sinistres de la branche automobile, par exercice de survenance et année de développement. Montants en milliers d'euros.

Surv. / Dév.	0	1	2	3	4	5
2020	12 450	21 800	26 100	27 950	28 700	28 950
2021	13 200	22 950	27 400	29 200	29 950	
2022	14 100	24 350	29 050	30 980		
2023	15 050	25 880	30 720			
2024	16 200	27 600				
2025	17 350					

Coefficients de passage Chain-Ladder

Passage	$f_{t \rightarrow t+1}^{(0)}$	$f_{t \rightarrow t+1}^{(1)}$	$f_{t \rightarrow t+1}^{(2)}$	$f_{t \rightarrow t+1}^{(3)}$	$f_{t \rightarrow t+1}^{(4)}$
Valeur	1,7345	1,1923	1,0658	1,0259	1,0087

5. Pyramide des assurés par région

Répartition du portefeuille au 31/12/2025 (nombre de contrats actifs, toutes branches confondues).

Région	< 30 ans	30–49 ans	50–64 ans	65+ ans	Total
Île-de-France	42 380	68 920	39 450	28 110	178 860
Auvergne-Rhône-Alpes	28 950	52 480	31 200	24 890	137 520
PACA	19 220	38 700	26 850	22 410	107 180
Nouvelle-Aquitaine	16 480	33 950	24 100	20 880	95 410
Occitanie	17 320	34 280	23 890	20 050	95 540
Hauts-de-France	21 100	39 750	23 480	17 920	102 250
Grand Est	18 650	35 200	22 980	18 480	95 310
Bretagne	12 480	26 920	18 100	15 720	73 220
Autres régions	32 100	61 240	39 280	31 950	164 570
Total France	208 680	391 440	249 330	200 410	1 049 860

6. Architecture du pipeline RAG

Le pipeline RAG (Retrieval-Augmented Generation) déployé dans le cadre de ce projet repose sur cinq composants principaux : ingestion, chunking, embedding, indexation vectorielle et génération. Chaque composant peut être instrumenté indépendamment pour mesurer la qualité de l'ensemble.

Composant	Outil retenu	Version	Hébergement
Ingestion	docling	2.95	On-premise
Chunking	LangChain RecursiveSplitter	0.3.x	On-premise
Embedding	BGE-M3 (FlagOpen)	1.5	On-premise GPU
Vector store	Qdrant	1.11	Cluster interne
LLM	Mistral 7B Instruct	v0.3	Ollama local
Re-ranker	BGE-reranker-v2-m3	1.0	On-premise GPU
Orchestration	LangGraph	0.2	On-premise

L'ensemble tourne dans un environnement isolé sans accès internet, conformément aux exigences de confidentialité des données actuarielles manipulées.

7. Comparatif de modèles open weights

Benchmarks publics au 1er trimestre 2026, modèles instruct, quantisation Q4_K_M pour comparaison équitable.

Modèle	Paramètres	Context	MMLU	HumanEval	MT-Bench	VRAM Q4
Llama 3.1 8B	8 B	128k	68,4	62,2	8,1	6,1 Go
Mistral 7B v0.3	7 B	32k	62,5	30,5	7,3	5,4 Go
Qwen 2.5 7B	7 B	128k	74,2	57,9	8,4	5,8 Go
Gemma 2 9B	9 B	8k	71,3	40,2	8,0	6,9 Go
Phi-3.5 Mini	3,8 B	128k	69,0	62,8	8,3	2,9 Go
Mixtral 8×7B	47 B (MoE)	32k	70,6	40,2	8,3	26,4 Go
Llama 3.1 70B	70 B	128k	82,4	80,5	9,0	40,2 Go

Les modèles MoE comme Mixtral offrent un excellent compromis performance/coût en inférence, mais nécessitent que l'ensemble des experts soient chargés en VRAM même si une fraction seulement est activée par token.

8. Sinistralité par garantie — Exercice 2025

Fréquence et coût moyen observés sur le portefeuille multirisque habitation, échantillon 100 % France métropolitaine.

Garantie	Nb sinistres	Fréquence	Coût moyen (€)	Charge totale (k€)
Dégât des eaux	48 920	4,82 %	1 245	60 905
Incendie	3 850	0,38 %	8 920	34 342
Vol	12 480	1,23 %	2 850	35 568
Bris de glace	22 100	2,18 %	485	10 719
Catastrophes naturelles	6 720	0,66 %	4 280	28 762
Responsabilité civile	9 350	0,92 %	1 920	17 952
Tempête / grêle	14 280	1,41 %	2 150	30 702
Total	117 700	11,60 %	1 868	218 950

Le dégât des eaux reste le sinistre dominant en fréquence, mais l'incendie concentre le coût moyen le plus élevé. Les événements climatiques (cat-nat, tempête) progressent significativement par rapport à l'exercice précédent.

9. Annexes — Glossaire d'acronymes

Acronyme	Signification
SCR	Solvency Capital Requirement
MCR	Minimum Capital Requirement
BEL	Best Estimate Liabilities
ORSA	Own Risk and Solvency Assessment
IFRS 17	International Financial Reporting Standard 17
GLM	Generalized Linear Model
LDA	Loss Distribution Approach
VaR	Value at Risk
TVaR	Tail Value at Risk
RAG	Retrieval-Augmented Generation
LLM	Large Language Model
OCR	Optical Character Recognition
PDF	Portable Document Format

10. Contacts

Rôle	Nom	Email	Téléphone
Chef de projet	Marie Dupont	m.dupont@example.fr	01 23 45 67 89
Actuaire référent	Jean Martin	j.martin@example.fr	01 23 45 67 90
Data scientist	Sophie Lambert	s.lambert@example.fr	01 23 45 67 91
DPO	Pierre Rousseau	dpo@example.fr	01 23 45 67 92